

Ders Tanıtımı

Bu seri, bilgisayarlı görü temellerini kurup modern Vision Transformer yaklaşımlarına geçişi akademik bir çerçevede sunar.

- Eğitim 1: problem formülasyonu, veri temsili, filtreleme/kenar çıkarımı, temel CNN yapı taşları ve metrikler.
- Amaç: klasik yöntemlerden derin öğrenmeye geçiş için sağlam sezgiler oluşturmak.

Görüntü Temsili ve Normalizasyon

Konuya Giriş


Görüntüler sayısal tensörlerdir ve her piksel bir veya birden fazla kanalla temsil edilir. Renk uzayı, bu kanalları standart bir yapıda ifade eder; RGB bu bağlamda en yaygın temsil biçimidir. Modelin daha hızlı ve kararlı öğrenebilmesi için girişler uygun ölçeklere çekilir; standardizasyon bu amaçla en yaygın kullanılan dönüşümlerden biridir.

$$p_{ij} = [r_{ij}, g_{ij}, b_{ij}]$$

$$I_g = 0.299R + 0.587G + 0.114B$$

$$I' = \frac{I - \mu}{\sigma}$$

- RGB $\rightarrow$ gri dönüşümde kanallar ağırlıklandırılır
- Standardizasyon: ölçek ve kaydırma ile daha kararlı eğitim



Renk Uzayları ve Dönüşümler I

Konuya Giriş

Renk uzayı, renk bilgisini belirli bir geometri ve kanal tanımıyla ifade eder. RGB yaygındır; HSV ve Lab gibi uzaylar ise algısal özellikleri daha iyi temsil edebilir.

- **Alt başlıklar:** RGB/HSV/Lab/YUV, kanal ayrışması, kullanım senaryoları
- **Teknolojiler:** OpenCV `cvtColor`, `COLOR_RGB2HSV`, CLAHE



Renk Uzayları ve Dönüşümler II

Konuya Giriş

Renk uzayları arasında dönüşüm yapılırken kanal ilişkileri değişir ve bu durum görsel algıyı ve ölçümleri etkileyebilir. Dönüşüm kalitesi, sonraki işleme adımlarının doğruluğunu belirler.

- **Alt başlıklar:** gri dönüşüm, histogram eşitleme, renk tutarlılığı
- **Teknolojiler:** `equalizeHist`, CLAHE, white balance yaklaşımları



Histogram ve CDF

Konuya Giriş

Histogram, görüntüdeki yoğunlukların (ör. 0–255 arası tonların) dağılımını verir ve kontrast hakkında bilgi taşır. CDF ise bu dağılımın birikimli formudur ve özellikle histogram eşitleme gibi işlemlerde temel bir araç olarak kullanılır.


Histogram:

$$h(k) = \#\{(x, y) : I(x, y) = k\}$$

CDF:

$$H(k) = \sum_{j=0}^k h(j)$$

- Histogram: yoğunluk dağılımı
- CDF: birikimli dağılım (eşitleme için kullanılır)




Veri Anotasyonu ve Protokoller I

Konuya Giriş

Etiket kalitesi, model performansını doğrudan sınırlar. Tutarlı anotasyon ve doğru değerlendirme protokolü, karşılaştırılabilir sonuçlar üretir.

- **Alt başlıklar:** yönergeler, tutarlılık, kalite kontrol
- **Teknolojiler:** CVAT, Label Studio, COCO/VOC formatları




Veri Anotasyonu ve Protokoller II

Konuya Giriş

Değerlendirme protokolü, model karşılaştırmalarının güvenilir olmasını sağlar. Yanlış ayırım veya sızıntı, performansı yapay olarak yükseltebilir.

- **Alt başlıklar:** veri ayırımı, sızıntı, raporlama
- **Teknolojiler:** pycocotools, standart değerlendirme scriptleri



Konvolüsyon, Stride, Padding


Konuya Giriş

Konvolüsyon, bir filtrenin yerel pencerede kaydırılmasıyla özniteliklerin çıkarılmasını sağlar. Filtreleme çoğu zaman ön işleme amaçlıdır ve gürültüyü azaltarak analizi kolaylaştırır. Stride ve padding, filtrenin nasıl kaydırıldığını ve çıktı çözünürlüğünü belirleyerek hem hesaplama maliyetini hem de kapsama alanını kontrol eder.

$$(I * K)(x, y) = \sum_{i=-k}^k \sum_{j=-k}^k I(x+i, y+j)K(i, j)$$

$$H_{out} = \left\lfloor \frac{H - K + 2P}{S} \right\rfloor + 1$$

$$W_{out} = \left\lfloor \frac{W - K + 2P}{S} \right\rfloor + 1$$



- K : filtre boyutu, S : stride, P : padding
- Çıkış boyutu çözünürlüğü belirler

Gaussian Filtre


Konuya Giriş

Gaussian filtre, yüksek frekanslı gürültüyü bastırmak için kullanılan yumuşatıcı bir çekirdektir. Gürültü; hareket, ışık dengesizliği, lens kusurları veya elektronik etkilerden kaynaklanabilir. Sürekli Gauss dağılımının ayırık örneklenmesiyle elde edilir ve σ parametresi bulanıklık seviyesini belirler.

Gaussian:

$$K(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right)$$

- σ arttıkça yumuşatma (blur) artar
- Gürültü azaltma ve ölçekli özellik çıkarımı




Konuya Giriş

Kenarlar, komşu piksellerin yoğunluk değerlerinin hızlı değiştiği bölgeleri temsil eder ve görüntüdeki yapısal bilgiyi taşır. Gradyan vektörü hem değişim yönünü hem de büyüklüğünü verir; bu nedenle kenar tespiti için temel bir ölçüttür.

$$\nabla I = \begin{bmatrix} \partial I / \partial x \\ \partial I / \partial y \end{bmatrix}, \quad |\nabla I| = \sqrt{(\partial I / \partial x)^2 + (\partial I / \partial y)^2}$$

- Gradyan büyüklüğü kenar şiddetini verir
- Sobel gibi filtreler ayrık türevi hesaplar




Canny Adımları

Konuya Giriş

Canny algoritması, gürültüye dayanıklı ve ince kenarlar üretmek amacıyla ardışık adımlardan oluşur. Pratikte sık tercih edilir; çünkü yanlış kenarları azaltıp güçlü kenarları koruma eğilimindedir.

Canny:

- smoothing: gürültü azaltma
- gradient: yön ve büyüklük
- non-max suppression: ince kenar
- double threshold: güçlü/zayıf kenar ayrımı
- hysteresis: bağlı zayıf kenarları koru




Konuya Giriş

Klasik bilgisayarlı görü yöntemleri, veri girişi ve ön işlemeden başlayıp öznitelik çıkarımı ve karar verme aşamalarına ilerleyen bir akış izler. Bu yaklaşım, basit ve hızlı bir tespit hattı kurmak için öğretici bir referans sağlar.

$$I \rightarrow I_g \rightarrow I_b \rightarrow E \rightarrow \{C_i\} \rightarrow B$$


- I_g : grayscale
- I_b : Gaussian blur
- E : Canny edges
- C_i : contours
- B : bounding box



Bounding Box Görselleřtirme

Konuya Giriř

Algoritmanın ıktısını görsel olarak doęrulamak, hataları hızlıca tespit etmeyi saęlar. Kutu etiketleri, hem konum doęruluęunu hem de sınıf bilgisini deęerlendirmek için kullanılır.




Yeniden Örnekleme ve Aliasing I

Konuya Giriş

Görüntü yeniden örnekleme, çözünürlük değişimi sırasında bilgi kaybına yol açabilir. Doğru enterpolasyon ve düşük geçiren filtreleme, aliasing etkilerini azaltır.

- **Alt başlıklar:** enterpolasyon, örnekleme teorisi, aliasing
- **Teknolojiler:** OpenCV `resize`, `INTER_NEAREST/LINEAR/CUBIC`




Yeniden Örnekleme ve Aliasing II

Konuya Giriş

Çözünürlüğü düşürmek, yüksek frekans bileşenlerini koruyamayan bir işlemdir. Bu nedenle uygun filtreleme ve oran seçimi, görsel sadakati korumada kritiktir.

- **Alt başlıklar:** anti-alias filtreleme, aspect ratio, moiré
- **Teknolojiler:** GaussianBlur, pyrDown, ölçek piramitleri




Veri Artırma ve Normalizasyon I

Konuya Giriş

Veri artırma, modelin genelleme kabiliyetini artırmak için örnek çeşitliliği sağlar. Normalizasyon yalnızca eğitim verisine göre hesaplanmalı ve tüm veri setlerine uygulanmalıdır.

- **Alt başlıklar:** geometrik/fotometrik artırma, etiket tutarlılığı
- **Teknolojiler:** Albumentations, torchvision transforms, imgaug




Veri Artırma ve Normalizasyon II

Konuya Giriş

Normalizasyon, farklı ölçeklerdeki girdileri ortak bir dağılıma yaklaştırır. Bu işlem eğitim kararlılığını artırır ve optimizasyonu hızlandırır.

- **Alt başlıklar:** standardizasyon, sızıntı önleme, dağılım kayması
- **Teknolojiler:** Normalize, dataset pipeline kontrolleri



Konuya Giriş

Modelin eğitim verisine iyi uyması tek başına yeterli değildir; asıl hedef, görülmemiş veri üzerinde düşük hata elde etmektir. Bu nedenle beklenen risk, ampirik riskle yaklaştırılır ve veri eğitim/validasyon/test olarak ayrılır.

$$\hat{R}(\theta) = \frac{1}{N} \sum_{i=1}^N L(f_{\theta}(x_i), y_i)$$

$$R(\theta) = \mathbb{E}_{(x,y) \sim p}[L(f_{\theta}(x), y)]$$

split then fit



- $\hat{R}$: eğitim verisi üzerindeki ampirik risk
- R : gerçek dağılım üzerindeki beklenen risk
- Split $\rightarrow$ fit (train) $\rightarrow$ transform (val/test)

Problem Formulation

Konuya Giriş

Bilgisayarlı görüde temel amaç, bir görüntüyü sayısal bir tensör olarak ele alıp bu tensörden anlamlı bir çıktı üretmektir. Dijital görüntü, satır-sütun düzeninde piksellerden oluşan bir matristir ve piksel görüntünün en küçük birimidir. Çıktı bir sınıf etiketi, bir nesne kutusu veya pikseller düzeyinde bir maske olabilir. Aşağıdaki gösterim, girdinin boyutlarını ve modelin bu girdiyi bir çıktı uzayına eşlediğini açık biçimde tanımlar.

$$I \in \mathbb{R}^{H \times W \times C}, \quad f_{\theta} : \mathbb{R}^{H \times W \times C} \rightarrow \mathcal{Y}$$

- I : girdi görüntü tensörü (yükseklik, genişlik, kanal)
- f_{θ} : parametrelili model fonksiyonu
- $\mathcal{Y}$: çıktı uzayı (sınıf, kutu, maske vb.)



Konuya Giriş

Bilgisayarlı görü problemleri, üretilen çıktının yapısına göre ayrılır. Bu ayrım, etiketleme stratejisini, kayıp fonksiyonunu ve değerlendirme metriklerini doğrudan belirler. Aşağıdaki formülasyonlar, üç temel görevin çıktı biçimlerini özetler.

- Classification (tek etiket):


$$f_{\theta}(I) = y, \quad y \in \{1, \dots, K\}$$

- Detection (kutu + sınıf + skor):

$$f_{\theta}(I) = \{(b_i, c_i, s_i)\}_{i=1}^N$$

- Segmentation (piksel düzeyi):

$$f_{\theta}(I) = M, \quad M \in \{0, 1, \dots, K\}^{H \times W}$$



CNN Katmanları ve Receptive Field I

Konuya Giriş

CNN mimarileri; konvolüsyon, havuzlama ve normalizasyon bileşenlerinin birleşimidir. Receptive field, bir nöronun girdide kapsadığı alanı tanımlar ve derinlikle büyür.

- **Alt başlıklar:** conv/pool/BN/dropout, özellik hiyerarşisi
- **Teknolojiler:** PyTorch Conv2d, BatchNorm2d, Keras Conv2D



CNN Katmanları ve Receptive Field II

Konuya Giriş

Receptive field büyüdükçe daha geniş bağlam yakalanır; bu durum yüksek seviyeli özelliklerin öğrenilmesini kolaylaştırır. Ancak etkili receptive field, teorikten küçüktür.

- **Alt başlıklar:** teorik/etkili RF, stride/padding, dilasyon
- **Teknolojiler:** dilated conv, FPN/pyramid yapıları



ReLU Aktivasyon


Konuya Giriş

Derin ağlarda doğrusal olmayanlık olmadan karmaşık karar sınırları öğrenilemez. ReLU, negatif değerleri sıfırlayarak basit bir eşikleme yapar ve pratikte hızlı ve kararlı optimizasyon sağlar.

ReLU:

$$\phi(z) = \max(0, z) \quad , \quad \phi'(z) = \mathbb{I}[z > 0]$$

- Negatifleri sıfırlar, doğrusal olmayanlık katar
- Türevi basit ve hesaplaması hızlı



Softmax ve Cross-Entropy

Konuya Giriş

Sınıflandırmada model çıktıları önce olasılık dağılımına dönüştürülür. Softmax bu dönüşümü gerçekleştirir; cross-entropy ise tahmin edilen dağılımın gerçek etiketlerle uyumsuzluğunu ölçer.


Softmax:

$$\hat{y}_c = \frac{e^{z_c}}{\sum_{j=1}^K e^{z_j}}$$

Cross-Entropy:

$$L = - \sum_{c=1}^K y_c \log(\hat{y}_c)$$

- Softmax: skorları olasılığa normalize eder
- Cross-Entropy: doğru sınıfa odaklanan kayıp



Optimizasyon

Konuya Giriş

Eğitim süreci, kayıp fonksiyonunu minimize edecek parametreleri bulma problemidir. Gradyan inişi temel yaklaşımken, Adam gibi yöntemler momentum ve adaptif ölçekleme ile daha hızlı ve dengeli yakınsama sağlar.


GD:

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L$$

Adam (özet):

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

- η : öğrenme oranı
- Adam: momentum + adaptif ölçekleme




Overfitting ve Düzenleştirme I

Konuya Giriş

Model kapasitesi arttıkça eğitim hatası düşse de genelleme hatası artabilir. Düzenleştirme teknikleri, modeli basitleştirerek aşırı öğrenmeyi sınırlar.

- **Alt başlıklar:** bias-variance, öğrenme eğrileri, kapasite kontrolü
- **Teknolojiler:** erken durdurma, çapraz doğrulama




Overfitting ve Düzenleştirme II

Konuya Giriş

Düzenleştirme, modelin karmaşıklığını kontrol ederek genelleme performansını artırır. Uygun strateji seçimi, veri miktarı ve görev türüne göre değişir.

- **Alt başlıklar:** L2/weight decay, dropout, lr schedule
- **Teknolojiler:** cosine/step schedulers, regularization ayarları



Sınıflandırma Metrikleri

Konuya Giriş


Dengesiz veri kümelerinde tek başına doğruluk ölçütü yeterli değildir. Precision ve recall, hata türlerini ayırt eder; F1 ise bu iki ölçütün dengeli bir ortalamasını sağlar.

$$P = \frac{TP}{TP + FP}$$

$$R = \frac{TP}{TP + FN}$$

$$F1 = \frac{2PR}{P + R}$$

- Precision: pozitif tahminlerin doğruluğu
- Recall: gerçek pozitiflerin yakalanma oranı
- F1: precision ve recall dengesi




IoU (Intersection over Union)

Konuya Giriş

Nesne tespitinde kutuların ne kadar örtüştüğünü ölçmek kritik bir adımdır. IoU, tahmin ve gerçek kutunun kesişiminin birleşime oranı olarak tanımlanır ve eşikleme kararları için standart bir metriktir.

$$IoU = \frac{\text{Area}(B_{pred} \cap B_{gt})}{\text{Area}(B_{pred} \cup B_{gt})}$$

- Kutu örtüşme oranı, eşikleme için kullanılır



mAP ve PR Eğrisi

Konuya Giriş


Precision-Recall eğrisi, farklı eşiklerde model davranışını gösterir. Interpolasyon, PR eğrisinin üst zarfını kullanarak AP değerini daha kararlı bir şekilde hesaplamayı sağlar; mAP ise sınıflar ortalamasıdır.

Interpolated AP:

$$AP = \sum_n (R_n - R_{n-1}) P_{\text{interp}}(R_n)$$

$$P_{\text{interp}}(R) = \max_{\tilde{R} \geq R} P(\tilde{R})$$

$$mAP = \frac{1}{K} \sum_{k=1}^K AP_k$$




- Precision zarfı ile AP hesaplanır
- Sınıflar ortalaması mAP

Detection ve Segmentation Kayıpları I

Konuya Giriş

Nesne tespiti ve segmentasyon problemlerinde sınıf dengesizliği ve geometrik uyum önemlidir. Bu nedenle standart CE kaybına ek olarak IoU-tabanlı ve sınıf ağırlıklı kayıplar kullanılır.

- **Alt başlıklar:** kutu regresyonu, sınıflandırma, çoklu kayıp
- **Teknolojiler:** Smooth L1, GloU/DIoU, focal loss




Detection ve Segmentation Kayıpları II

Konuya Giriş

Segmentasyonda hedef, piksel düzeyinde doğru ayrımı sağlamaktır. Bu nedenle bölge örtüşmesini ölçen kayıplar daha anlamlıdır.

- **Alt başlıklar:** Dice/IoU, sınıf dengesizliği, sınır kalitesi
- **Teknolojiler:** Dice/Tversky, BCE, boundary loss



YOLO Kutu Çözümleme

Konuya Giriş

YOLO, kutu parametrelerini doğrudan regresyon ile tahmin eder ve hücre/anchor tabanlı bir parametrizasyon kullanır. Bu sayede çıktıların fiziksel olarak geçerli aralıklarda olması sağlanır ve öğrenme daha kararlı hale gelir.

Anchor parametreleme:

$$b_x = \sigma(t_x) + c_x, \quad b_y = \sigma(t_y) + c_y$$

$$b_w = p_w e^{t_w}, \quad b_h = p_h e^{t_h}$$



- σ : merkez ofsetlerini $[0,1]$ aralığına sıkıştırır
- p_w, p_h : anchor boyutları

NMS (Non-Maximum Suppression)

Konuya Giriş


Bir nesne için birden fazla yüksek skor elde etmek yaygındır. NMS, en güvenilir kutuyu seçip yüksek örtüşmeye sahip diğerlerini bastırarak tekil ve temiz bir çıktı üretir.

NMS:

$$b^* = \arg \max_b s(b)$$

$\{b : IoU(b, b^*) \geq \tau_{nms}\}$ bastır

- En yüksek skorlu kutu seçilir
- Yüksek IoU olanlar elenir



Scaled Dot-Product Attention


Konuya Giriş

Attention, her tokenın diğer tokenlara göre önemini hesaplayarak bağlamsal bir temsil üretir. Skorların $\sqrt{d_k}$ ile ölçeklenmesi, büyük boyutlarda sayısal kararlılığı artırır ve softmax dağılımını dengeler.

$$Q = XW_Q, K = XW_K, V = XW_V$$

$$\text{Att}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

- Ölçekleme $\sqrt{d_k}$ gradyan kararlılığı sağlar
- Softmax ile satır bazında dikkat dağılımı



Multi-Head Attention

Konuya Giriş


Tek bir dikkat mekanizması tek tip ilişkilere odaklanabilir. Multi-head yapı, farklı alt-uzaylarda paralel dikkat hesaplayarak daha zengin ve ayırt edici temsiller elde edilmesini sağlar.

Multi-head:

$$\text{MHA}(X) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W_O$$

$$\text{head}_i = \text{Att}(XW_Q^{(i)}, XW_K^{(i)}, XW_V^{(i)})$$

- Farklı alt-uzaylarda paralel dikkat
- Birleştirme sonrası lineer projeksiyon



Transformer Encoder Bloğu

Konuya Giriş

Transformer bloğu, attention ve MLP katmanlarını residual bağlantılarla birleştirir. Pre-norm düzeni, derin ağlarda gradyan akışını iyileştirerek eğitimi kolaylaştırır.

Block (pre-norm):

$$Z = X + \text{MHA}(\text{LN}(X))$$

$$Y = Z + \text{MLP}(\text{LN}(Z))$$

- Önce LN, sonra blok (pre-norm)
- Residual bağlantılar derinlikte stabilite sağlar



Patchify ve Gömme

Konuya Giriş


ViT yaklaşımı görüntüyü sabit boyutlu patch'lere bölerek diziye dönüştürür. Her patch, doğrusal bir projeksiyonla bir token vektörüne gömülür ve böylece transformer giriş formatına uygun hale gelir.

Patch sayısı:

$$N = \frac{H}{p} \cdot \frac{W}{p}$$

Patch embedding:

$$E = X_p W_E + b_E, \quad E \in \mathbb{R}^{N \times d}$$



- p : patch boyutu, N : token sayısı
- Her patch lineer gömme ile vektöre dönüşür

Sinüzoidal Konum Kodlama

Konuya Giriş


Transformer mimarileri konumsal sıralamayı doğrudan bilmez. Sinüzoidal kodlama, her konuma özgü frekans temelli bir imza ekleyerek sıralama bilgisini modele taşır.

Positional encoding (sin/cos):

$$PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{2i/d}}\right)$$

$$PE_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{2i/d}}\right)$$

- Farklı frekanslar konumsal bilgiyi taşır
- Öğrenmeden sabit bir yapı sağlar



ViT Mimari Akış

Konuya Giriş

Vision Transformer, görüntüyü token dizisi olarak ele alır ve tamamen attention tabanlı katmanlarla işler. CLS token, sınıflandırma için küresel temsil oluşturur.




ViT Eğitim Stratejileri I

Konuya Giriş

ViT modelleri genellikle büyük veriyle ön-eğitim ve ardından hedef görevde ince ayar gerektirir. CLS token, tüm diziyi özetleyen bir temsil olarak sınıflandırmada kullanılır.

- **Alt başlıklar:** pretrain/finetune, veri ölçeği, transfer
- **Teknolojiler:** MAE, DeiT, DINO



Konuya Giriş

Transformer tabanlı modellerde konum bilgisi kritik bir bileşendir. CLS token ve positional encoding, çıktı temsilini güçlendirmek için birlikte çalışır.

- **Alt başlıklar:** CLS token, positional encoding, düzenleme
- **Teknolojiler:** stochastic depth, mixup, CutMix



Karmaşıklık ve Gecikme

Konuya Giriş

Model seçimi, hesaplama maliyeti ve gerçek zamanlılık gereksinimlerinden doğrudan etkilenir. Attention, token sayısına göre karesel ölçeklenirken; gecikme ölçümleri sistem seviyesinde performansı değerlendirmek için kullanılır.


Karmaşıklık:

$$\text{CNN: } O(HWK^2C_{in}C_{out})$$

$$\text{Attn: } O(N^2d)$$

$$T_{total} = T_{pre} + T_{model} + T_{post} \quad , \quad FPS = \frac{1}{T_{total}}$$


- Attention: token sayısı ile karesel ölçek
- Gecikme toplamı FPS'i belirler



Latency Pipeline

Konuya Giriş

Uçtan uca gecikme, ön-işleme, model çıkarımı ve son-işleme sürelerinin toplamıdır. Bu ayrışım, darboğazları belirlemek ve sistem optimizasyonu yapmak için kritik önem taşır.




Verimlilik ve Model Sıkıştırma I

Konuya Giriş

Uygulama tarafında gecikme ve bellek kısıtları kritik olabilir. Sıkıştırma teknikleri, doğruluk-kaynak dengesini optimize etmeyi amaçlar.

- **Alt başlıklar:** latency/throughput, bellek/enerji
- **Teknolojiler:** ONNX Runtime, TensorRT, TFLite




Verimlilik ve Model Sıkıştırma II

Konuya Giriş

Sıkıştırma yöntemleri, hesaplama maliyetini düşürürken doğruluğu mümkün olduğunca korur. Uygun yöntem seçimi, hedef donanım ve uygulama gereksinimine bağlıdır.

- **Alt başlıklar:** quantization, pruning, distillation
- **Teknolojiler:** PTQ/QAT, pruning kitleri, distillation



Ekler: LaTeX Paketleri ve Temalar

- `beamer`: sunum yapısı, slayt düzeni ve temalar
- `graphicx`: görsel ekleme ve ölçekleme
- `amsmath`, `amssymb`: matematiksel gösterimler ve semboller
- `fontenc`, `inputenc`: yazı kodlaması ve UTF-8 desteği
- **Tema/renc**: CambridgeUS + dolphin ile akademik görünüm

Ekler: Model Katmanları

- **Conv2D**: yerel pencerelerde ağırlıklı toplam ile öznitelik çıkarır
- **BatchNorm**: ara aktivasyonları normalize ederek eğitimi kararlı yapar
- **ReLU**: negatif değerleri sıfırlayarak doğrusal olmayanlık ekler
- **Pooling**: uzamsal boyutu düşürür, özetleme etkisi sağlar
- **MLP**: doğrusal katmanlar ile global temsil gücü artırılır
- **Attention/MHA**: tokenlar arası ilişkileri ağırlıklı toplamla modeller

Ekler: Temel Fonksiyonlar

- **Softmax**: skorları olasılığa dönüştürür, toplamı 1 yapar
- **Cross-Entropy**: doğru sınıfa odaklanan olasılık kaybı
- **IoU**: kutu örtüşmesini ölçer, eşikleme için kullanılır
- **NMS**: yüksek örtüşmeli kutuları bastırarak tekil çıktı üretir
- **Gaussian**: gürültü bastırma ve yumuşatma için çekirdek
- **Sobel/Canny**: gradyan tabanlı kenar tespiti yöntemleri